

INFORME: COMPARACIÓN DE ÁRBOLES DE DECISIÓN EN EL PROGRAMA WEKA

1. Introducción y Metodología

Se compararon los resultados del algoritmo de árbol de decisión J48 implementado en la suite de minería de datos WEKA. El análisis se aplicó sobre el conjunto de datos clásico 'diabetes' (Pima Indians Diabetes) bajo dos escenarios experimentales distintos:

- 1. Datos Originales (Sin Procesar):** El dataset se evaluó en su estado inicial, manteniendo los valores '0' dentro de variables continuas que reflejan errores de medición o campos vacíos.
- 2. Datos Preprocesados (Limpios):** Se aplicó un filtrado avanzado para identificar y mitigar las anomalías fisiológicas. Primero, mediante el filtro NumericCleaner, los ceros biológicamente imposibles en los atributos 'plas', 'pres', 'skin', 'insu' y 'mass' se transformaron en valores faltantes (NaN). Posteriormente, se utilizó el filtro ReplaceMissingValues para imputar dichos vacíos utilizando la media estadística de las columnas respectivas.

2. Comparación Estructural de los Árboles de Decisión

El comportamiento del algoritmo J48 varió significativamente según la calidad de los datos de entrada:

- **Identificación de Variables Críticas:** En ambos escenarios, las variables más determinantes y posicionadas en la cúspide jerárquica del árbol (nodos raíz y subdivisiones primarias) correspondieron a 'plas' (glucosa en plasma) y 'mass' (índice de masa corporal). Esto corrobora el alto peso clínico de ambos indicadores para predecir la diabetes.
- **Complejidad y Profundidad del Modelo:** El árbol sin procesar generó una estructura más compacta debido a que los ceros erróneos distorsionaban la varianza, deteniendo prematuramente la ramificación. Por el contrario, el árbol preprocesado incrementó su tamaño general y profundidad; al remover el ruido de los falsos ceros, el algoritmo J48 logró discriminar relaciones matemáticas más sutiles y ramificó variables antes ignoradas en niveles profundos, tales como 'skin', 'insu' y 'pres'.

Figura 1: Diagrama del árbol con datos sin procesar





Figura 2: Diagrama del árbol con datos preprocesados



3. Resultados Generales y Métricas de Rendimiento

A continuación se presenta la tabla comparativa con los indicadores clave de rendimiento obtenidos en WEKA:

Métrica / Resumen Estadístico	Modelo Sin Procesar	Modelo Preprocesado
Instancias Clasificadas Correctamente	117(75.974 %)	118 (76.6234 %)
Instancias Clasificadas Incorrectamente	37(24.026 %)	36 (23.3766 %)
Estadístico Kappa	0.4493	0.443
Error Absoluto Medio (MAE)	0.3022	0.2919
Error Cuadrático Medio (RMSE)	0.430	0.4127
Error Absoluto Relativo (RAE)	67.456 %	65.1461 %
Error Cuadrático Relativo (RRSE)	92.006 %	88.2991 %

Análisis de Desempeño: El tratamiento de los datos aporta típicamente una optimización en el poder predictivo general. El modelo limpio registra cambios en las tasas de acierto y una reducción en las métricas de error (MAE y RMSE), demostrando que las predicciones del árbol limpio son estadísticamente más robustas y consistentes frente a información distorsionada.

4. Análisis de la Matriz de Confusión

Las matrices detallan la distribución de errores de clasificación entre las categorías de control y casos de estudio (negativo = no tiene diabetes, positivo = sí tiene diabetes):

	Sin procesar		Preprocesado	
	Pred. negativo	Pred. positivo	Pred. negativo	Pred. positivo
Real negative	86	19	90	15
Real positivo	18	31	21	28

Evaluación de Diagnósticos: El preprocesamiento causa un impacto en la sensibilidad y especificidad del clasificador. Al limpiar falsos ceros, el árbol equilibra su capacidad discriminatoria basándose exclusivamente en distribuciones matemáticas puras y sin sesgos artificiales.

5. Conclusión

El proceso de limpieza de datos demostró ser una fase fundamental para la construcción de un modelo predictivo confiable. Aunque las ganancias en precisión global varíen según la muestra, el modelo preprocesado es exponencialmente más coherente desde una perspectiva clínica. El primer árbol tomaba decisiones basándose en axiomas médicos incorrectos (como asumir que una presión arterial o un IMC de 0 son parámetros viables de salud), induciendo al sobreajuste (overfitting). El segundo modelo extrae reglas fundamentadas puramente en información biológica real, incrementando la validez analítica del árbol de decisiones final.